2ª Entrega – Álgebra Linear, Vetores e Geometria Analítica

Integrantes

Breno Costa
Bruno Souza
Felipe Toshio
Vinícius Nishimura

Objetivo: Complementar a entrega anterior com uma operação mais avançada de Álgebra Linear para que o funcionamento do agente fique mais fluido e assertivo.

Contextualização: Na entrega anterior, o grupo desenvolveu o "Agente para o estudante" utilizando as operações de Produto Escalar e Norma para calcular a similaridade do cosseno, a fim de identificar o tema da pergunta feita ao agente. Porém, depois de alguns testes práticos durante o desenvolvimento do projeto, percebemos que essa abordagem tem limitações, causadas pelo espaço vetorial em que a similaridade é calculada (uma dimensão por palavra), e não pelo cosseno em si. Nesta 2ª entrega, iremos analisar essa etapa utilizando a operação de redução de dimensionalidade com SVD, para posteriormente decidirmos quais operações usar em determinadas situações.

1 Similaridade do cosseno sobre TF-IDF e o problema

```
# ============================================================
# 6. ÁLGEBRA LINEAR: PRODUTO ESCALAR E SIMILARIDADE DE COSSENO
# ============================================================

# cálculo manual, pra deixar explícita a fórmula por trás do cosine_similarity:
v = vetor_pergunta.toarray()[0]
r0 = X[0].toarray()[0]
produto_escalar_manual = np.dot(v, r0)
sim_manual = produto_escalar_manual / (np.linalg.norm(v) * np.linalg.norm(r0) + 1e-9)
print("Exemplo manual (pergunta x 1º registro) — produto escalar:", round(produto_escalar_manual, 4),
      "| cosseno:", round(sim_manual, 4))

# vetorizado, contra todos os registros de uma vez:
similaridades = cosine_similarity(vetor_pergunta, X)[0]
```

Na prática, a similaridade do cosseno é calculada a partir do **produto escalar e das normas dos vetores**.

- Mede a proximidade entre os vetores independentemente de sua magnitude.
- Valores próximos de 1 indicam maior similaridade entre a pergunta e o registro histórico, enquanto valores próximos de 0 indicam menor similaridade.

O problema é que cada palavra é uma dimensão independente, então o método só reconhece palavras **idênticas**. Ele não sabe que "declaração" e "atestado" têm o mesmo sentido.

Além disso, palavras raras recebem peso alto no TF-IDF e podem dominar o resultado. Ou seja, a problemática não é o cosseno em si, e sim o espaço onde ele é calculado: com uma dimensão por palavra, esparso e sem noção de sentido.

2 Redução de dimensionalidade (SVD) e como ela resolve

```python
# ============================================================
# 10. ÁLGEBRA LINEAR AVANÇADA: SVD (ANÁLISE SEMÂNTICA LATENTE)
# ============================================================
# X ≈ U Σ Vᵀ. Os valores singulares (σ) são as raízes dos autovalores
# de XᵀX, e as linhas de Vᵀ (svd.components_) são seus autovetores.
# Mantendo só os k maiores, cada registro passa a ser um vetor de k
# "conceitos" em vez de uma dimensão por palavra. Assim, termos que
# aparecem nos mesmos contextos (ex: "boleto" e "pagamento") ficam
# próximos, mesmo sem palavras idênticas na pergunta.

# escolha de k: menor número de componentes que preserva 80% da variância
k_max = min(200, X.shape[1] - 1, X.shape[0] - 1)
svd_full = TruncatedSVD(n_components=k_max, algorithm="arpack", random_state=42).fit(X)
var_acum = svd_full.explained_variance_ratio_.cumsum()
K = max(10, int(np.argmax(var_acum >= 0.80)) + 1) if (var_acum >= 0.80).any() else k_max

svd = TruncatedSVD(n_components=K, algorithm="arpack", random_state=42)
X_red = normalize(svd.fit_transform(X))   # normalizado: produto escalar = cosseno

print("\n" + "=" * 60)
print("ENTREGA 2 - SVD")
print("=" * 60)
print(f"Dimensões: {X.shape[1]} termos -> {K} componentes "
      f"({var_acum[K-1]:.1%} da variância preservada)")
print("Matriz reduzida de registros:", X_red.shape)
```

A ideia. A matriz TF-IDF possui 477 dimensões (palavras). Com a SVD, conseguimos reduzir essa quantidade e agrupar palavras que aparecem em contextos semelhantes, formando 44 conceitos principais. Esses conceitos representam assuntos presentes nos registros, em vez de palavras isoladas.

Relação com autovalores e autovetores. Também verificamos a relação entre a SVD e os autovalores da matriz. Os três primeiros valores encontrados foram idênticos nos dois métodos:

- SVD (σ^2): 9945,5722 | 6120,5518 | 4581,0694
- Autovalores: 9945,5722 | 6120,5518 | 4581,0694

Isso confirma a relação matemática entre os dois cálculos.

Escolha de k. Definimos que a redução deveria preservar pelo menos 80% da informação original. O resultado foi:

- Dimensões originais: 477
- Componentes mantidos: 44
- Variância preservada: 80,2%

O que os componentes representam? Ao analisar as palavras mais importantes de cada componente, identificamos assuntos como:

- Componente 1: serviços, solicitações, alunos e estágios.
- Componente 2: estágios, documentação e contratos.
- Componente 3: carteirinhas, confecção e retirada.

Como isso resolve o problema? Em vez de comparar apenas palavras iguais, o agente passa a comparar os assuntos dos registros. Assim, palavras relacionadas podem contribuir para encontrar solicitações semelhantes, mesmo quando não são exatamente iguais. Isso ajuda a reduzir a influência de palavras pouco relevantes e melhorar a identificação do contexto da pergunta.

3 Execução do notebook e diferença entre os resultados

Similaridade do cosseno (TF-IDF)

```
Matriz de registros históricos: (96628, 477)
Digite a pergunta do estudante: perdi minha carteirinha preciso de outra
Exemplo manual (pergunta x 1º registro) — produto escalar: 0.0 | cosseno: 0.0

Registros mais semelhantes à pergunta:
                                Motivo do Contato Tema Relacionamento  \
59634  Prouni: Transferência para Outra Instituição     Risco de Evasão
3986   Prouni: Transferência para Outra Instituição     Risco de Evasão
91322  Prouni: Transferência para Outra Instituição     Risco de Evasão
65872  Prouni: Transferência para Outra Instituição     Risco de Evasão
87866  Prouni: Transferência para Outra Instituição     Risco de Evasão

       similaridade
59634      0.594313
3986       0.594313
91322      0.594313
65872      0.594313
87866      0.594313

Motivo identificado: Prouni: Transferência para Outra Instituição

Orientação: sua solicitação foi identificada como 'Prouni: Transferência para Out
```

No exemplo manual, o produto escalar e o cosseno valem 0,0 porque o primeiro registro do histórico não possui nenhuma palavra em comum com a pergunta. Não se trata de

um erro: é justamente o comportamento esperado do método, que só enxerga palavras idênticas.

Redução de dimensionalidade (SVD)

```
============================================================
ENTREGA 2 - SVD
============================================================
Dimensões: 477 termos -> 44 componentes (80.2% da variância preservada)
Matriz reduzida de registros: (96628, 44)

σ² (SVD):            [9945.5722 6120.5518 4581.0694]
Autovalores de XᵀX:  [9945.5722 6120.5518 4581.0694]

Principais componentes (conceitos):
  Componente 1: serviço, especial, solicitação, aluno, estágio, entrega
  Componente 2: estágio, entrega, documentação, solicitação, aluno, contrato
  Componente 3: fecap, carteirinha, confecção, retirada, solicitação, aluno

Registros mais semelhantes à pergunta (com SVD):
                       Motivo do Contato   Tema Relacionamento  similaridade
69341  Confecção da carteirinha da FECAP  Solicitação de Aluno      0.866598
48885  Confecção da carteirinha da FECAP  Solicitação de Aluno      0.866598
21845  Confecção da carteirinha da FECAP  Solicitação de Aluno      0.866598
21834  Confecção da carteirinha da FECAP  Solicitação de Aluno      0.866598
21836  Confecção da carteirinha da FECAP  Solicitação de Aluno      0.866598

Motivo identificado (SVD): Confecção da carteirinha da FECAP

Orientação (SVD): sua solicitação foi identificada como 'Confecção da carteirinha d

------------------------------------------------------------
```

Após executar o notebook e inserir a pergunta “perdi minha carteirinha preciso de outra”, as duas operações geram respostas e encaminhamentos totalmente diferentes. Nesse caso, a redução de dimensionalidade foi mais adequada entre as duas.

Critério	**TF-IDF**	**TF-IDF + SVD**
Dimensões	477	44
Variância preservada	—	80,2%
Similaridade máxima	0,5943	0,8666
Motivo identificado	Prouni: Transferência para Outra Instituição	Confecção da carteirinha da FECAP
Tema do relacionamento	Risco de Evasão	Solicitação de Aluno
Resultado	Incorreto	Adequado (mesmo assunto da pergunta)

Atenção ao comparar as similaridades. Os valores de 0,5943 e 0,8666 não são comparáveis entre si, pois pertencem a espaços vetoriais diferentes: no espaço reduzido, as similaridades tendem a ser mais altas de forma geral. Uma similaridade maior, por si só, não significa um resultado melhor, e o limiar de confiança definido na Entrega 1 precisa ser recalibrado para o novo espaço.

O TF-IDF tradicional acabou dando importância à palavra "outra", relacionando-a aos registros de transferência para outra instituição. Com isso, o estudante seria encaminhado como um caso de *Risco de Evasão*, quando na verdade pedia uma nova carteirinha.

Já a SVD conseguiu representar melhor o contexto da pergunta. Isso aconteceu porque a pergunta foi aproximada de um componente relacionado a termos como "carteirinha", "confecção" e "retirada". Assim, mesmo sem encontrar exatamente as mesmas palavras, conseguiu aproximar a pergunta dos registros sobre confecção de carteirinha, e o tema passou a ser *Solicitação de Aluno*. Vale observar que a base também possui o motivo "Confecção da Carteirinha – 2ª Via", mais específico para quem perdeu a carteirinha. A SVD acertou o assunto, mas não necessariamente o motivo mais específico.

O que podemos analisar para melhorar o agente?

- **Qualidade dos registros:** identificar motivos duplicados, inconsistentes ou classificados incorretamente. Nos resultados acima, os cinco registros mais semelhantes têm exatamente a mesma similaridade (0,594313 no TF-IDF e 0,866598 no SVD), ou seja, são registros com o mesmo texto. De fato, a base tem 96.628 registros, mas apenas 322 combinações distintas de motivo e tema. Na prática, o "top 5" representa um único motivo.
- **Escolha do número de componentes:** testar diferentes valores de k para verificar se conseguimos preservar mais informação ou melhorar a classificação.
- **Palavras pouco relevantes:** analisar termos que causam associações incorretas, como "outra".
- **Limiar de similaridade:** testar diferentes valores para evitar que o agente classifique perguntas sem correspondência adequada.
- **Testes com perguntas reais:** criar um conjunto de perguntas com respostas conhecidas e comparar a taxa de acerto dos métodos.

Conclusão. Neste caso, a SVD apresentou um resultado mais adequado ao reduzir a influência de coincidências entre palavras e identificar relações entre termos de contextos semelhantes. Isso indica que a redução de dimensionalidade tende a ser mais útil quando a pergunta usa palavras que diferem do histórico ou contém palavras raras que confundem o TF-IDF. Entretanto, essa hipótese ainda precisa ser confirmada com diferentes perguntas, para avaliar a precisão de forma mais ampla e definir em quais situações cada operação deve ser usada. A qualidade dos dados, a escolha dos componentes e o ajuste do limiar são os próximos pontos de melhoria do agente ASA.